Generative KI-Modelle und ihre mathematischen Grundlagen

Orhan Konak
Hochschule Bremen
10.04.2026

Warum sprechen alle über Generative KI?

- ChatGPT schreibt Texte
- Midjourney erzeugt Bilder
- KI generiert Code, Musik, medizinische Daten

→ Systeme erzeugen *neue Inhalte*, nicht nur Vorhersagen

Aber: *Was passiert dabei eigentlich mathematisch?*

Zentrale Fragestellung

Wie kann ein Modell Daten erzeugen, die es nie zuvor gesehen hat?

- Lernen wir Muster?
- Lernen wir Regeln?
- Oder etwas anderes?

Bottom Line:

- Wir lernen eine *Wahrscheinlichkeitsverteilung*

Agenda

- Was bedeutet „Generieren“ überhaupt?
- Wie beschreiben wir Daten mathematisch?
- Wie lernen Modelle solche Verteilungen?
- Beispiel: Generierung mit Diffusion Models

Diskriminative vs. Generative Modelle

Diskriminative Modelle

- Lernen: $p(y \mid x)$
- Klassifikation / Regression
- Beispiel: Spam-Erkennung

Generative Modelle

- Lernen: $p(x)$ oder $p(x, y)$
- Ziel: Daten erzeugen
- Beispiel: Bildgenerierung

Generative Modelle lernen die *Struktur der Daten selbst*

Daten als Wahrscheinlichkeitsverteilung

Inhalt:

- Daten sind nicht zufällig
- Sie folgen einer Struktur
- Diese Struktur kann als Verteilung beschrieben werden

Mathematisch:

- $x \sim p_{\text{data}}(x)$

Interpretation:

- Ziel: Diese unbekannte Verteilung approximieren

Generieren = Ziehen von Stichproben

Wenn wir $p(x)$ kennen, können wir:

$$x \sim p(x)$$

→ neue Daten erzeugen

Beispiel:

- Bilder
- Texte
- Signale

- **Generative KI = Lernen + Sampeln**

Das zentrale Problem

- Die echte Verteilung $p_{\text{data}}(x)$ ist unbekannt

Herausforderung:

- hochdimensional (z. B. Bilder)
- komplex
- nicht analytisch gegeben

Ziel:

- $p_\theta(x) \approx p_{\text{data}}(x)$

Zentrale Idee generativer Modelle

Wir starten mit einfacher Zufälligkeit → und transformieren sie in Daten

Schema:

$$z \sim \mathcal{N}(0, I) \quad \Rightarrow \quad x = f_\theta(z)$$

Interpretation:

- z: einfacher Zufallsvektor
- f_θ: gelerntes Modell

→ Aus Rauschen wird Struktur

Ein alternativer Ansatz: Diffusion Models

Statt direkt zu generieren:

Idee:

- Daten → schrittweise zerstören
- Modell lernt: diesen Prozess umzukehren

Kernaussage:

- Lernen durch „Rückwärtsdenken“

Intuition: Vom Bild zum Rauschen

- Schritt 1: Bild leicht verrauschen
- Schritt 2: mehr Rauschen
- …
- Am Ende: reines Rauschen

→ Prozess ist einfach modellierbar

Forward Process (Zerstörung)

Mathematisch:

$$q(x_t \mid x_{t-1}) = \mathcal{N}\left(x_t; \sqrt{1-\beta_t}\, x_{t-1}, \beta_t I\right)$$

Erklärung:

- β_t: Rauschstärke
- Schrittweise wird Rauschen hinzugefügt

→ Nach vielen Schritten:

$$x_T \sim \mathcal{N}(0, I)$$

Reverse Process (Generierung)

Ziel: Rauschen wieder entfernen

$$p_\theta(x_{t-1} \mid x_t)$$

Modell lernt:

- Wie sah der vorherige Zustand aus?

→ Schritt für Schritt entsteht ein Bild

Was wird eigentlich gelernt?

Modell lernt, das Rauschen zu schätzen

$$\epsilon_\theta(x_t, t)$$

Interpretation:

- Vorhersage des hinzugefügten Rauschens
- Subtraktion → sauberes Signal

→ Einfaches Lernziel, starke Wirkung

Trainingsziel

Mathematisch:

$$\mathcal{L} = \mathbb{E}[|\epsilon - \epsilon_\theta(x_t, t)|^2]$$

Interpretation:

- Modell soll echtes Rauschen rekonstruieren

→ MSE als Loss

Generierung neuer Daten

1. Starte mit Zufallsrauschen
2. Wende Reverse Process an
3. Schrittweise entsteht Struktur

Am Ende:

- Bild
- Text
- Signal

Zusammenfassung

- Generative Modelle lernen Verteilungen
- Ziel: neue Daten erzeugen
- Diffusion Models:
- Vorwärts: Rauschen hinzufügen
- Rückwärts: Struktur rekonstruieren

→ Lernen durch Invertieren eines Prozesses

Transfer – Wo wird das eingesetzt?

- Bildgenerierung (Stable Diffusion)
- Medizinische Bildgebung
- Datenaugmentation
- Simulation

→ Große Bedeutung für Forschung & Praxis

Transfer – Wo wird das eingesetzt?

- Bildgenerierung (Stable Diffusion)
- Medizinische Bildgebung
- Datenaugmentation
- Simulation

→ Große Bedeutung für Forschung & Praxis

Weiterführende Quellen

Videos

- Diffusion Models: DDPM | Generative AI Animated (Deepia ~ 32 min)
- But how do AI images and videos actually work? | Guest video by Welch Labs (3Blue1Brown and Welch Labs ~ 37 min)
- Diffusion Models | Paper Explanation | Math Explained (Outlier ~ 33 min)

Folien

- Diffusion (Hao Chen @Carnegie Mellon University)
- Variational Autoencoders and Diffusion Models (Ruiqi Gao @Stanford cs231n)

Bücher

- Hands-On Generative AI with Transformers and Diffusion Models (Omar Sanseviero et al.)
- Learn Generative AI with PyTorch (Mark Liu)

Kontakt

Mail:
konak@uni-potsdam.de

Folien von heute

https://github.com/konakion/extremwertaufgaben